

Предиктивные модели на основе семантических признаков

Принцип работы


1. От данных к смыслу: Традиционные метрики (количество просмотров, лайков) не отражают суть контента. Семантические признаки раскрывают его скрытые качества и аудиторное восприятие.

2. Универсальный цифровой язык: Технологии эмбединга (LLM, мультимодальные энкодеры) переводят неструктурированные данные (текст, изображения, аудио) в векторные представления — «цифру», пригодную для аналитических моделей.

3. Точность прогноза: Включение семантических признаков значительно повышает точность моделей, так как они захватывают фундаментальные причины сигнала (настроение, стиль, релевантность), а не просто следствия.

4. Решение проблемы «хвоста»: Семантика особенно эффективна для прогнозирования успеха нишевого или нового контента, где исторических метрик мало или нет. Это решает проблему несбалансированных данных.


5. Прямая монетизация: Увеличение точности прогнозов напрямую конвертируется в финансовые результаты через оптимизацию инвестиций в контент и рекламные кампании.



Кейсы

Кейс 1: Tokenised Music — Прогнозирование популярности музыкальных треков

- **Задача:** Оценка будущей популярности (количество прослушиваний) треков и портфелей для инвестиционных решений.
- **Технология:** Модели-трансформеры для анализа и эмбединга музыкальных и текстовых данных.
- **Семантические признаки:**
 - Прямые: Аудио-фичи (темп, тональность, энергия).
 - Косвенные (ключевые для успеха): Семантика комментариев и контента подписчиков артиста в соцсетях. Это позволило оценить лояльность и вовлеченность фанатов.
- **Результат:**
 - **Устойчивое прогнозирование для жанров R&B, Dance, Pop с MAPE < 30% на 365 дней по входящим 60 дням.**
 - Построение вариационного ряда прослушиваний на год вперед.
 - **Преодоленный вызов:** Решена проблема несбалансированности классов (успешных треков мало) за счет привлечения семантических данных из соцсетей.
 - Эффект: Рост точности инвестиционных решений, прямой денежный эффект.





Кейс 2: DSP Сеть — Предсказание CTR баннерной рекламы

- **Задача:** Оценка Click-Through Rate (CTR) рекламного баннера до запуска кампании для выбора наиболее эффективного креатива.
- **Технология:**
 - Текст: Многоклассовая классификация и эмбединг контента веб-страницы.
 - Изображение: Мультимодальный энкодер для анализа семантики баннера.
- **Семантические признаки:**
 - Тематика и тональность текста на странице размещения.
 - Визуальный стиль, композиция и смысловое содержание баннера.
- **Результат:** Модель с **Subset Accuracy = 70%**, что означает высокую точность предсказания лучшего баннера для заданного контекста.

Subset Accuracy = 70% означает, что мы сначала прогнозируем CTR (регрессия), а затем на основе этого прогноза выбираем лучший баннер (решающая задача). И в 70% случаев модель выбирает баннер, который и в реальности оказывается самым кликабельным. Это уже метрика для оценки итогового бизнес-решения, а не чисто ML-модели.

- **Эффект:** Рост эффективности рекламных кампаний, оптимизация медиазакупок, прямой денежный эффект.



Executive summary

Семантические признаки — это не просто еще один набор фич, а качественный скачок в предиктивной аналитике. Они позволяют перейти от корреляционного анализа к каузальному пониманию, почему тот или иной контент или актив будет успешен. Реализованные кейсы в музыке и рекламе доказывают: кодирование смысла в цифру дает измеримый рост точности и прямую финансовую отдачу.